Kategorisch Train

January 14, 2021

1 Trainieren des neuronalen Netzes Kategorisch

Zu Beginn müssen wieder alle Bibliotheken eingebunden werden.

[6]:
```
#import all necessary packages
import os
import numpy as np
import pandas as pd
import tensorflow as tf
from tensorflow import keras
import IPython
import kerastuner as kt
```

Für den Fall, dass die bereits mit Skript 1 vorbereiteten Datensätze nicht im selben Verzeichnis wie die Python-Datei liegt muss das Verzeichnis des Datensatzes angegeben werden. Dies kann mittels folgendem Befehl durchgeführt werden:

[7]:
```
#function to set the start working directory manually
#not necessary, if the .py file is executed in the directory of the .csv files
#os.chdir('D:\\OneDrive - bwedu\\Uni\\09 ABC 1\\Neuronale␣
 ↪Netzwerke\\Python\\Wein')
```

Nun muss das Arbeitsverzeichnis geändert werden. Dabei wird das Arbeitsverzeichnis so geändert, dass auf die zuvor vorbereiteten Daten zugegriffen werden kann.

Codeabsatz 1 speichert das aktuelle Arbeitsverzeichnis.

Codeabsatz 2 ändert das Arbeitsverzeichnis.

Codeabsatz 3 importiert die mittels Datenvorbereitungsskript zuvor erstellten Daten.

Codeabsatz 4 convertiert die Daten in ein numpy-Array.

Dabei ist zu beachten, dass die erste Spalte des Datensatzes nicht von Relevanz ist und daher nicht beachtet wird.

Die Daten werden von Kategorie 3-9 in Kategorie 0-6 konvertiert.

Im letzten Codeabsatz wird nach dem Import der Daten wieder in das Ausgangsverzeichnis gewechselt.

[8]:
```
#save the current working directory
current_wd = os.getcwd()

#change the working directory to the 'prep_dataset' directroy, where the␣
 ↪prepared data a saved as .csv files
os.chdir('prep_dataset')

#import the prepared data as panda dataframes
W_train_samples = pd.read_csv('wine_train_samples.csv')
W_train_labels = pd.read_csv('wine_train_labels_cont.csv')

#convert panda dataframe to a numpy array
#leave out the first column, because this are the rownumernumbers
W_train_samples = pd.DataFrame.to_numpy(W_train_samples)[:,1:13]
W_train_labels = pd.DataFrame.to_numpy(W_train_labels)[:,1]-3

#change the working directory back to the original working directory
os.chdir(current_wd)
```

Folgende Codezeilen erzeugen ein zufälliges neuronales Netz (model_builder), welches später trainiert werden kann.

Zu beachten ist, dass dem model_builder die Parameter (Anzahl layer, learning Rate und Anzahl Knoten) systematisch auswählt.

Für dieses Beispiel kann der model_builder die Parameter in folgenden Bereichen wählen:

Anzahl hidden layer: 1-5

Learning Rate: 1e-5 bis 1e-4

Knoten der hidden Layer: 16-160 (Differenz der Anzahl an Knoten zwischen den einzelnen Layer: 16 Knoten)

Aktivierungsfunktion: relu bzw. softmax

relu:

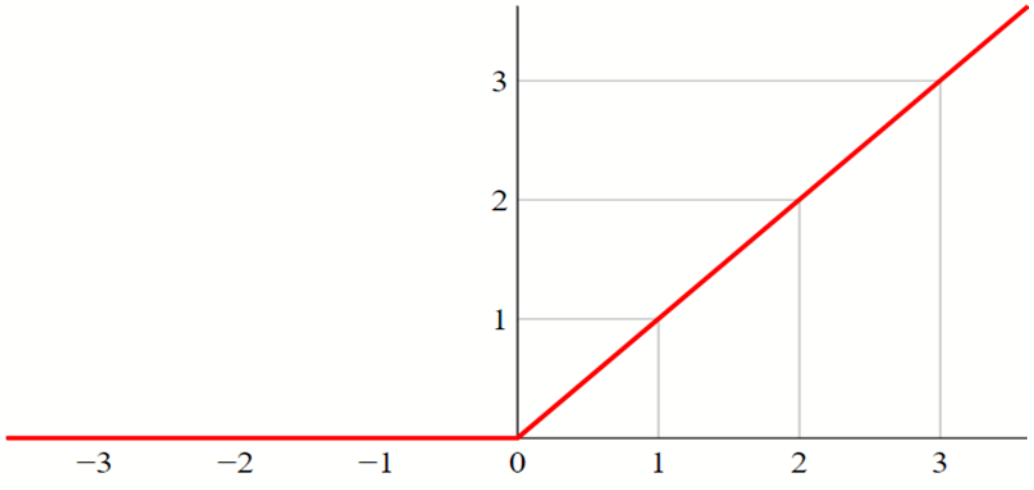

1

1 https://upload.wikimedia.org/wikipedia/commons/c/c9/Ramp_function.svg

softmax:

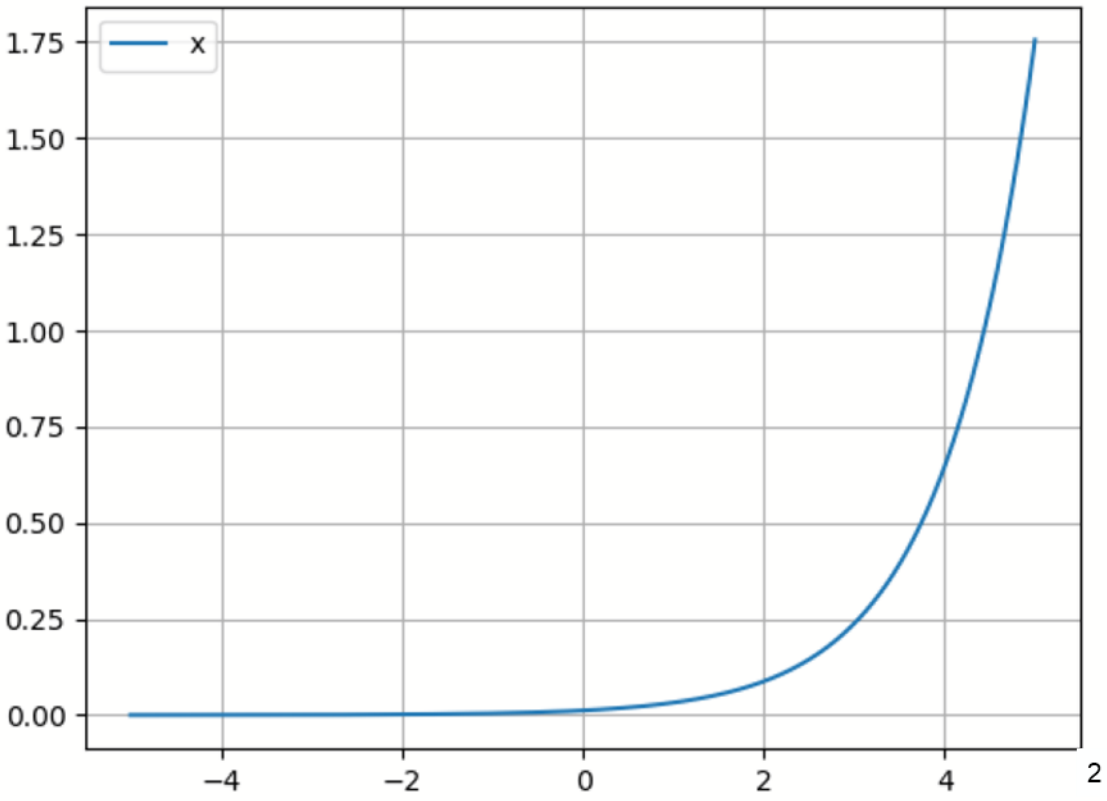

Beim kompilieren des Modells ist zu beachten, dass hier als Fehler (loss) die sparse categorial crossentropy berechnet wird.

Zum Schluss wird das fertige Modell zurückgegeben.

[9]:
```
#the definition of the model building function
#here it is possible to specify the model, the most parameters
#with hp funcitions it is possible to specify a range of values, in which an␣
↪optimizer can optimize the model
def model_builder(hp):
    #the number of layers in a range from 1 to 5
        hp_layers = hp.Int('layers', min_value = 1, max_value = 5)
    #test different learning rates
        hp_learning_rate = hp.Choice('learning_rate', values = [1e-4, 3*1e-5,␣
↪1e-5])
```

2 https://www.machinecurve.com/wp-content/uploads/2020/01/softmax_logits.png

```
        #the input layer with 12 nodes
        inputs = keras.Input(shape=(12,))

        x = inputs
        for i in range(hp_layers):
                #for each layer a different number of nodes (16 to 160)
                x = keras.layers.Dense(units = hp.Int('units_' + str(i),
            min_value = 16, max_value = 160, step = 16), activation = "relu")(x)

        #the output layer with 7 nodes
        outputs = keras.layers.Dense(7, activation = "softmax")(x)

        #set the model together
        model = keras.Model(inputs, outputs)

        #compile the model
        model.compile(optimizer = keras.optimizers.Adam(learning_rate
                  = hp_learning_rate),
                                            loss = keras.losses.
↪SparseCategoricalCrossentropy(from_logits = True),
                                            metrics = ['accuracy'])

        return model #return the finished model
```

Da die Daten im Weindatensatz (Qualität 3-9) nicht ausgeglichen sind, werden diese hier mit Gewichtungen versehen (class_weight), man beachte, dass Python hier die Zählung mit 0 beginnt (0-6 entspricht Güte 3-9).

Im 2. Absatz werden die einzelnen Einstellungen für den tuner definiert.

Wichtig: Sollte die Optimierung mehrmals wiederholt werden, so muss vor jeder Wiederholung zuerst das Verzeichnis des vorherigen tunings manuell gelöscht werden.

[10]:
```
# the weights to consider the circumstance, that the training data aren't␣
↪distributed equally
class_weight = {0: 9.4, 1: 1.3, 2: 0.13, 3: 0.1, 4: 0.26, 5: 1.47, 6: 56.7}

#set settings for the tuner
tuner = kt.Hyperband(model_builder,
                     objective = 'val_accuracy',
                     max_epochs = 400,

                     factor = 3, #the higher, the faster the optimizing, but␣
↪the smalles the probability to find the best model

                            #how often should search the optimizer for optimal␣
↪model
```

```
                                                    hyperband_iterations =␣
↪1,



                    #!!!delete directory before optimizing again!!!
                    directory = 'tuner_wine_cat_full', #where should the␣
↪optimizer save the log files for the optimizing
                    project_name = 'wine_quality_advanced')
```

In unserem Code verwenden wir sogenannte Callback-Funktionen.

Sobald über 10 Epochen (patience) kein Fortschritt (Verbesserung der Genauigkeit) mehr erreicht wird, wird das Training abgebrochen.

[11]:
```
#define the necessary callbacks
early_stopping_cb = keras.callbacks.EarlyStopping(patience=10,␣
↪restore_best_weights=True)
```

Nun werden die erzeugten neuronalen Netze optimiert. Folgende Parameter werden dafür verwendet:

```
epochs: 400 -> Insgesamt maximal 400 Wiederholungen
batch_size: 12 -> Paralleses Training des neuronalen Netzes durch Daten
validation_split: 0.1 -> 10% der Daten werden für eine Validation verwendet
callbacks (Abruf wie oben definiert)
```

[12]:
```
#start the optimizer
tuner.search(W_train_samples, W_train_labels, epochs = 400, batch_size = 12,␣
↪validation_split = 0.1, callbacks = [early_stopping_cb] ,class_weight =␣
↪class_weight)
```

```
Trial 725 Complete [00h 02m 40s]
val_accuracy: 0.3603448271751404

Best val_accuracy So Far: 0.5189655423164368
Total elapsed time: 01h 04m 08s
INFO:tensorflow:Oracle triggered exit
```

Durch folgenden Befehl wird aus allen getesteten neuronalen Netzen das beste ausgewählt und gespeichert (alle anderen neuronalen Netze werden nicht beachtet).

[13]:
```
# Get the optimal hyperparameters
best_hps = tuner.get_best_hyperparameters(num_trials = 1)[0]
```

Durch folgenden print-Befehl werden die vorher definierten Parameter des besten neuronalen Netzes am Bildschirm ausgegeben.

[14]:
```
#print the results of the optimizer
print(f"""
```

```
                The hyperparameter search is complete.
                Learning rate: {best_hps.get('learning_rate')}
                Number of Layers: {best_hps.get('layers')}
                """)
for i in range(best_hps.get('layers')):
        print("Number of nodes in layer %i: %f" %(i, best_hps.get('units_' +␣
 ↪str(i))))
```

```
                The hyperparameter search is complete.
                Learning rate: 0.0001
                Number of Layers: 2

Number of nodes in layer 0: 160.000000
Number of nodes in layer 1: 112.000000
```

Durch folgenden Befehl wird die log file directory für die graphische Darstellung mittels tensorboard definiert.

[15]:
```
#define the log-directory for the logfiles for tensorboard
root_logdir = os.path.join(os.curdir, "my_logs")
def get_run_logdir():
        import time
        run_id = 'wine_quality_cat_full_' + time.
 ↪strftime("run_%Y_%m_%d-%H_%M_%S")
        return os.path.join(root_logdir, run_id)
run_logdir = get_run_logdir() # e.g., './my_logs/run_2019_06_07-15_15_22'
```

Die callbacks werden wie folgt implementiert:

Codezeile 1: Speichern des besten Resultats als “wine_quality_cat_full4.h5”

Codezeile 2: Das neuronale Netz speichert immer nur das Modell mit der höchsten Genauigkeit als Variable in Python.

Codezeile 3: Das neuronale Netz stoppt das Training, wenn nach 20 Wiederholungen keine weitere Erhöhung der Genauigkeit stattfindet.

[16]:
```
#define the necessary callbacks
checkpoint_cb = keras.callbacks.ModelCheckpoint("wine_quality_cat_full4.h5",␣
 ↪save_best_only=True)
early_stopping_cb2 = keras.callbacks.EarlyStopping(patience=20,␣
 ↪restore_best_weights=True)
tensorboard_cb = keras.callbacks.TensorBoard(run_logdir)
```

In folgendem Schritt wird das optimale Modell der Variable model zugewiesen, die nun das optimale untrainierte neuronale Netz repräsentiert, das anschließend noch trainiert werden muss.

[17]:
```
# Build the model with the optimal hyperparameters
model = tuner.hypermodel.build(best_hps)
```

Mit folgendem Befehl erfolgt das finale Training des neuronalen Netzes. Mit der batch_size 6, maximal 1000 Epochen, 10% der Daten als Validierung und der callback-Funktionen.

[18]:
```
#train the model
history = model.fit(W_train_samples, W_train_labels, shuffle = True, batch_size␣
↪= 1, epochs = 1000, validation_split = 0.1, callbacks = [checkpoint_cb,␣
↪early_stopping_cb2, tensorboard_cb], class_weight = class_weight)
```

```
Epoch 1/1000
   1/5220 […] - ETA: 0s - loss: 0.2517 - accuracy:
0.0000e+00WARNING:tensorflow:From C:\Users\Tobia\anaconda3\lib\site-
packages\tensorflow\python\ops\summary_ops_v2.py:1277: stop (from
tensorflow.python.eager.profiler) is deprecated and will be removed after
2020-07-01.
Instructions for updating:
use `tf.profiler.experimental.stop` instead.
WARNING:tensorflow:Callbacks method `on_train_batch_end` is slow compared to the
batch time (batch time: 0.0010s vs `on_train_batch_end` time: 0.0326s). Check
your callbacks.
5220/5220 [==============================] - 4s 766us/step - loss: 0.5946 -
accuracy: 0.3500 - val_loss: 1.8723 - val_accuracy: 0.3862
Epoch 2/1000
5220/5220 [==============================] - 4s 711us/step - loss: 0.5882 -
accuracy: 0.2626 - val_loss: 1.8525 - val_accuracy: 0.3431
Epoch 3/1000
5220/5220 [==============================] - 4s 715us/step - loss: 0.5809 -
accuracy: 0.2841 - val_loss: 1.8112 - val_accuracy: 0.3655
Epoch 4/1000
5220/5220 [==============================] - 4s 698us/step - loss: 0.5757 -
accuracy: 0.2937 - val_loss: 1.8343 - val_accuracy: 0.2776
Epoch 5/1000
5220/5220 [==============================] - 4s 693us/step - loss: 0.5726 -
accuracy: 0.2807 - val_loss: 1.7801 - val_accuracy: 0.3690
Epoch 6/1000
5220/5220 [==============================] - 4s 707us/step - loss: 0.5698 -
accuracy: 0.3092 - val_loss: 1.8339 - val_accuracy: 0.2879
Epoch 7/1000
5220/5220 [==============================] - 4s 702us/step - loss: 0.5684 -
accuracy: 0.3153 - val_loss: 1.7907 - val_accuracy: 0.3379
Epoch 8/1000
5220/5220 [==============================] - 4s 690us/step - loss: 0.5670 -
accuracy: 0.3224 - val_loss: 1.7822 - val_accuracy: 0.3534
Epoch 9/1000
5220/5220 [==============================] - 4s 711us/step - loss: 0.5659 -
accuracy: 0.3218 - val_loss: 1.7720 - val_accuracy: 0.3586
Epoch 10/1000
5220/5220 [==============================] - 4s 703us/step - loss: 0.5649 -
accuracy: 0.3500 - val_loss: 1.8057 - val_accuracy: 0.3155
```

```
Epoch 11/1000
5220/5220 [==============================] - 4s 714us/step - loss: 0.5639 -
accuracy: 0.3297 - val_loss: 1.7310 - val_accuracy: 0.4397
Epoch 12/1000
5220/5220 [==============================] - 4s 712us/step - loss: 0.5625 -
accuracy: 0.3402 - val_loss: 1.7523 - val_accuracy: 0.4103
Epoch 13/1000
5220/5220 [==============================] - 4s 715us/step - loss: 0.5612 -
accuracy: 0.3603 - val_loss: 1.8115 - val_accuracy: 0.3241
Epoch 14/1000
5220/5220 [==============================] - 4s 701us/step - loss: 0.5608 -
accuracy: 0.3487 - val_loss: 1.8059 - val_accuracy: 0.3293
Epoch 15/1000
5220/5220 [==============================] - 4s 686us/step - loss: 0.5584 -
accuracy: 0.3433 - val_loss: 1.7538 - val_accuracy: 0.4069
Epoch 16/1000
5220/5220 [==============================] - 4s 691us/step - loss: 0.5589 -
accuracy: 0.3623 - val_loss: 1.8233 - val_accuracy: 0.3190
Epoch 17/1000
5220/5220 [==============================] - 4s 696us/step - loss: 0.5574 -
accuracy: 0.3563 - val_loss: 1.7582 - val_accuracy: 0.4034
Epoch 18/1000
5220/5220 [==============================] - 4s 705us/step - loss: 0.5567 -
accuracy: 0.3596 - val_loss: 1.7762 - val_accuracy: 0.3655
Epoch 19/1000
5220/5220 [==============================] - 4s 723us/step - loss: 0.5561 -
accuracy: 0.3536 - val_loss: 1.7439 - val_accuracy: 0.4103
Epoch 20/1000
5220/5220 [==============================] - 4s 719us/step - loss: 0.5557 -
accuracy: 0.3458 - val_loss: 1.7359 - val_accuracy: 0.4276
Epoch 21/1000
5220/5220 [==============================] - 4s 700us/step - loss: 0.5544 -
accuracy: 0.3527 - val_loss: 1.7355 - val_accuracy: 0.4431
Epoch 22/1000
5220/5220 [==============================] - 4s 699us/step - loss: 0.5543 -
accuracy: 0.3603 - val_loss: 1.7638 - val_accuracy: 0.3948
Epoch 23/1000
5220/5220 [==============================] - 4s 698us/step - loss: 0.5533 -
accuracy: 0.3690 - val_loss: 1.7701 - val_accuracy: 0.3931
Epoch 24/1000
5220/5220 [==============================] - 4s 702us/step - loss: 0.5527 -
accuracy: 0.3690 - val_loss: 1.7359 - val_accuracy: 0.4259
Epoch 25/1000
5220/5220 [==============================] - 4s 708us/step - loss: 0.5518 -
accuracy: 0.3621 - val_loss: 1.7816 - val_accuracy: 0.3810
Epoch 26/1000
5220/5220 [==============================] - 4s 714us/step - loss: 0.5488 -
accuracy: 0.3640 - val_loss: 1.7391 - val_accuracy: 0.4241
```

```
Epoch 27/1000
5220/5220 [==============================] - 4s 714us/step - loss: 0.5473 -
accuracy: 0.3594 - val_loss: 1.7573 - val_accuracy: 0.4121
Epoch 28/1000
5220/5220 [==============================] - 4s 701us/step - loss: 0.5437 -
accuracy: 0.3573 - val_loss: 1.7530 - val_accuracy: 0.4017
Epoch 29/1000
5220/5220 [==============================] - 4s 713us/step - loss: 0.5374 -
accuracy: 0.3642 - val_loss: 1.7642 - val_accuracy: 0.3879
Epoch 30/1000
5220/5220 [==============================] - 4s 718us/step - loss: 0.5408 -
accuracy: 0.3575 - val_loss: 1.7635 - val_accuracy: 0.3966
Epoch 31/1000
5220/5220 [==============================] - 4s 719us/step - loss: 0.5371 -
accuracy: 0.3529 - val_loss: 1.7613 - val_accuracy: 0.4017
```